

Pengaruh Penetrasi Akses Internet terhadap Indeks Pembangunan Manusia (IPM): Pendekatan Probabilitas dan Analisis Korelasi

Laporan Project Akhir Probabilitas dan Statistika

Alfitra Mumtaz Hanafi (J0403251058)

Ahmad Abian Hakim (J0403251069)

Rheika Muhammad Dzikrullah (J0403251068)

Zaky Alnadif (J0403251126) Natasha Umaiza (J0403251046)

Hilannisa Nuraini Al'Basr (J0403251022)

2026-06-08

BAB I: PENDAHULUAN

1.1 Latar Belakang

Dalam era modern, definisi infrastruktur pembangunan tidak lagi terbatas pada pembangunan fisik, melainkan telah berekspansi ke infrastruktur digital. Akses internet kini menjadi kebutuhan fundamental yang bertindak sebagai katalisator perputaran ekonomi, pemerataan pendidikan, dan akses informasi medis. Kesenjangan digital (*digital divide*) sering kali menjadi akar masalah ketimpangan kesejahteraan antarwilayah. Wilayah dengan penetrasi internet yang rendah cenderung mengalami stagnasi dalam peningkatan kualitas Sumber Daya Manusia (SDM). Oleh karena itu, penelitian ini bertujuan untuk mengevaluasi secara statistik probabilitas dan signifikansi korelasi ketersediaan akses internet terhadap Indeks Pembangunan Manusia (IPM) menggunakan bahasa pemrograman R.

1.2 Tujuan Analisis

Analisis ini memiliki tujuan antara lain:

1. Mengidentifikasi dan menangani *missing value* serta *outlier* pada dataset pembangunan wilayah, khususnya pada variabel akses internet dan IPM.

2. Melakukan statistika deskriptif untuk memetakan persebaran data digitalisasi dan kesejahteraan penduduk.
3. Membangun visualisasi data yang informatif untuk melihat tren sebaran antarvariabel secara grafis.
4. Menguji distribusi probabilitas (normalitas) pada data IPM wilayah.
5. Membuktikan secara statistik hipotesis korelasi antara penetrasi akses internet dengan skor IPM.

BAB II: METODOLOGI

2.1 Dataset

Penelitian ini menggunakan dataset `pembangunan_wilayah_missing_outlier.csv` yang merepresentasikan kondisi indikator pembangunan makro di berbagai wilayah. Fokus pengujian dibatasi pada variabel independen `akses_internet` (persentase ketersediaan fasilitas internet) dan variabel dependen `ipm` (Indeks Pembangunan Manusia). Dataset ini secara inheren memiliki *missing value* dan *outlier* yang disimulasikan untuk menguji ketahanan model pra-pemrosesan data sebelum uji hipotesis dieksekusi.

2.2 Tools yang Digunakan

Seluruh tahapan pembersihan dan pengujian data dieksekusi menggunakan bahasa pemrograman **R**. Dokumen ini disusun menggunakan **Quarto**, sebuah sistem penerbitan saintifik yang memungkinkan integrasi narasi teks dan eksekusi kode (*reproducible research*) secara instan ke dalam format PDF. Pustaka tambahan seperti `ggplot2` diimplementasikan untuk membangun visualisasi grafis yang komprehensif.

2.3 Metode Analisis

Pendekatan statistik yang diterapkan meliputi:

- **Penanganan Data:** Imputasi data kosong diselesaikan menggunakan Median Imputation untuk meminimalisasi efek distorsi akibat nilai ekstrem. Karena fokus penelitian adalah menguji hubungan antara **akses internet dan IPM**, analisis selanjutnya dilakukan menggunakan data **hasil imputasi** tanpa menghapus observasi yang terindikasi sebagai nilai ekstrem.

BAB III. HASIL DAN PEMBAHASAN

3.1 Gambaran Umum Analisis

Penelitian ini difokuskan untuk menguji apakah terdapat hubungan antara penetrasi akses internet dengan Indeks Pembangunan Manusia (IPM).

Secara sistematis, prosedur analisis dilakukan dalam beberapa tahapan krusial, dimulai dari persiapan data, eksplorasi deskriptif, visualisasi pola hubungan antarvariabel, pengujian asumsi normalitas, hingga diakhiri dengan uji korelasi. Mengingat dataset yang digunakan mengandung missing value, langkah awal yang dilakukan adalah pembersihan data untuk menjamin validitas hasil statistik. Setelah data dipastikan lengkap, dilakukan eksplorasi untuk memetakan karakteristik variabel, yang kemudian dilanjutkan dengan pengujian statistik untuk menjawab hipotesis mengenai signifikansi hubungan antara akses internet dan IPM.

3.2 Pembersihan Data dan Penanganan Missing Value

Tahap awal dalam alur kerja analisis ini adalah memastikan integritas data melalui pemeriksaan kualitas variabel. Keberadaan missing value pada dataset berisiko menimbulkan bias dalam perhitungan statistik sehingga diperlukan tindakan perbaikan sebelum analisis dilakukan. Untuk menangani hal tersebut, metode Median Imputation diterapkan, yakni mengganti nilai yang hilang dengan nilai median dari variabel terkait. Pemilihan metode ini didasarkan pada karakteristik median yang lebih resisten (*robust*) terhadap pengaruh nilai ekstrem (*pencilan*) dibandingkan dengan metode rata-rata (*mean*).

Berdasarkan pemeriksaan awal, ditemukan adanya missing value pada variabel akses internet dan IPM. Setelah proses imputasi dilakukan, data kini telah lengkap dan memenuhi syarat untuk diproses ke tahap analisis selanjutnya.

3.2.1 Pemeriksaan Missing Value

```
# Membuat folder gambar jika folder tersebut belum tersedia
if (!dir.exists("../gambar")) {
  dir.create("../gambar")
}

# Membaca dataset
data <- read.csv("../dataset/pembangunan_wilayah_missing_outlier.csv")

# Mengecek jumlah missing value pada seluruh variabel
missing_semua_variabel <- colSums(is.na(data))
```

```
cat("Jumlah missing value pada seluruh variabel:\n")
```

Jumlah missing value pada seluruh variabel:

```
print(missing_semua_variabel)
```

wilayah	provinsi	tahun	pdrb_perkapita
0	0	0	25
kemiskinan	pengangguran	ipm	harapan_hidup
24	25	25	0
rata_lama_sekolah	akses_internet	jalan_baik	air_bersih
0	25	25	0
catatan_data			
0			

```
# Mengecek jumlah missing value pada variabel utama
na_internet_awal <- sum(is.na(data$akses_internet))
na_ipm_awal <- sum(is.na(data$ipm))

cat("\nJumlah NA Akses Internet sebelum diolah:", na_internet_awal, "\n")
```

Jumlah NA Akses Internet sebelum diolah: 25

```
cat("Jumlah NA IPM sebelum diolah:", na_ipm_awal, "\n")
```

Jumlah NA IPM sebelum diolah: 25

```
# Mengisi missing value pada variabel utama dengan median
data$akses_internet[is.na(data$akses_internet)] <- median(data$akses_internet, na.rm = TRUE)
data$ipm[is.na(data$ipm)] <- median(data$ipm, na.rm = TRUE)

# Mengecek ulang missing value pada variabel utama setelah imputasi
cat("\nJumlah NA Akses Internet setelah diolah:", sum(is.na(data$akses_internet)), "\n")
```

Jumlah NA Akses Internet setelah diolah: 0

```
cat("Jumlah NA IPM setelah diolah:", sum(is.na(data$ipm)), "\n")
```

Jumlah NA IPM setelah diolah: 0

Berdasarkan hasil pemeriksaan, missing value ditemukan pada beberapa variabel dalam dataset. Namun, karena analisis ini berfokus pada hubungan antara **akses internet** dan IPM, proses imputasi hanya dilakukan pada variabel `akses_internet` dan `ipm`. Nilai yang hilang pada kedua variabel tersebut digantikan menggunakan median masing-masing variabel sehingga data utama yang digunakan dalam analisis menjadi lengkap.

3.2.2 Pemeriksaan Outlier

```
# Mengecek jumlah data berdasarkan catatan data
cat("Jumlah data berdasarkan catatan_data:\n")
```

Jumlah data berdasarkan `catatan_data`:

```
table(data$catatan_data)
```

Missing Value	Normal	Outlier
143	2337	20

Kolom `catatan_data` menunjukkan bahwa sebagian observasi dalam dataset teridentifikasi sebagai outlier, yakni nilai-nilai yang menyimpang secara signifikan dari pola mayoritas data. Mengingat fokus penelitian adalah menguji hubungan antara akses internet dan IPM, observasi tersebut tetap dipertahankan dalam analisis. Penghapusan outlier justru berisiko mempersempit variasi data dan mengurangi representativitas hasil, sehingga pendekatan yang dipilih adalah membiarkan data apa adanya setelah imputasi pada variabel utama diselesaikan.

3.3 Analisis Deskriptif

Setelah proses pembersihan data selesai, dilakukan analisis deskriptif untuk memperoleh gambaran umum mengenai karakteristik data. Analisis ini bertujuan mengetahui ukuran pemusatan dan penyebaran data seperti nilai minimum, maksimum, median, rata-rata, dan kuartil.

```
cat("Ringkasan Statistik Akses Internet:\n")
```

Ringkasan Statistik Akses Internet:

```
summary(data$akses_internet)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.01	39.09	58.09	58.78	78.58	97.99

```
cat("\nRingkasan Statistik IPM:\n")
```

Ringkasan Statistik IPM:

```
summary(data$ipm)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
55.01	62.60	69.89	69.90	77.09	84.99

Ringkasan statistik menggambarkan karakteristik sebaran nilai akses internet dan IPM di seluruh wilayah yang tercakup dalam dataset. Dari output yang dihasilkan, terlihat adanya variasi yang cukup lebar antarwilayah, baik pada tingkat penetrasi internet maupun skor IPM-nya. Kondisi ini mengindikasikan bahwa ketimpangan antardaerah masih cukup nyata, dengan sejumlah wilayah yang sudah berada jauh di atas rata-rata sementara sebagian lainnya masih tertinggal. Gambaran awal ini menjadi pijakan penting sebelum melangkah ke analisis hubungan antarvariabel pada tahap berikutnya.

3.4 Visualisasi Data

Visualisasi data digunakan untuk membantu melihat pola hubungan, bentuk distribusi, serta kemungkinan adanya nilai ekstrem pada variabel yang dianalisis. Pada bagian ini digunakan beberapa visualisasi, yaitu scatter plot, histogram, dan boxplot.


3.4.1 Scatter Plot Hubungan Akses Internet dan IPM

```
# Memanggil package ggplot2 untuk membuat visualisasi data
library(ggplot2)

# Membuat scatter plot hubungan akses internet dan IPM
plot_scatter <- ggplot(data, aes(x = akses_internet, y = ipm)) +
  geom_point(color = "#2980b9", alpha = 0.5) +
  geom_smooth(method = "lm", color = "#e74c3c", se = TRUE) +
  labs(
    title = "Hubungan Akses Internet dan IPM",
    x = "Akses Internet (%)",
    y = "IPM"
  ) +
  theme_minimal()

# Menampilkan plot pada laporan
plot_scatter
```

`geom\_smooth()` using formula = 'y ~ x'



```
# Menyimpan plot ke dalam folder gambar
ggsave(
  filename = "../gambar/scatter_akses_internet_ipm.png",
  plot = plot_scatter,
```

```
width = 8,  
height = 4,  
dpi = 300  
)
```

```
`geom_smooth()` using formula = 'y ~ x'
```


Berdasarkan Gambar 1, titik-titik data terlihat menyebar secara acak dan tidak membentuk pola naik atau turun yang jelas. Garis regresi pada grafik juga hampir datar, sehingga hubungan linear antara akses internet dan IPM belum terlihat kuat secara visual.

Dari visualisasi ini, dapat dikatakan bahwa wilayah dengan akses internet yang lebih tinggi tidak selalu memiliki IPM yang lebih tinggi dalam dataset ini. Oleh karena itu, hasil scatter plot perlu diperkuat dengan uji korelasi Pearson untuk mengetahui apakah hubungan kedua variabel signifikan secara statistik.

3.4.2 Histogram Distribusi IPM

Histogram digunakan untuk melihat bentuk distribusi nilai IPM pada dataset. Visualisasi ini membantu memberikan gambaran awal mengenai apakah data IPM cenderung menyebar secara normal atau tidak sebelum dilakukan uji normalitas.

```
# Membuat histogram untuk melihat distribusi nilai IPM  
plot_histogram_ipm <- ggplot(data, aes(x = ipm)) +  
  geom_histogram(bins = 30, fill = "#3498db", color = "white") +  
  labs(  
    title = "Distribusi Nilai IPM",  
    x = "IPM",  
    y = "Frekuensi"  
  ) +  
  theme_minimal()  
  
# Menampilkan histogram IPM pada laporan  
plot_histogram_ipm
```

```
# Menyimpan histogram IPM ke dalam folder gambar
ggsave(
  filename = "../gambar/histogram_ipm.png",
  plot = plot_histogram_ipm,
  width = 8,
  height = 4,
  dpi = 300
)
```

Berdasarkan Gambar 2, nilai IPM tersebar pada beberapa rentang nilai dan tidak sepenuhnya membentuk pola lonceng yang simetris. Hal ini menunjukkan bahwa distribusi IPM perlu diperiksa lebih lanjut sebelum digunakan dalam pengujian statistik.

Histogram ini hanya digunakan sebagai gambaran awal untuk melihat bentuk sebaran data. Keputusan mengenai normal atau tidaknya distribusi IPM tetap didasarkan pada hasil uji Shapiro-Wilk pada bagian berikutnya.

3.4.3 Boxplot Akses Internet dan IPM

Boxplot digunakan untuk melihat sebaran data, nilai tengah, rentang data, serta kemungkinan adanya nilai ekstrem pada variabel akses internet dan IPM.

```
# Mengubah data akses internet dan IPM ke format panjang
data_boxplot <- data.frame(
```


```

variabel = rep(c("Akses Internet", "IPM"), each = nrow(data)),
nilai = c(data$akses_internet, data$ipm)
)

# Membuat boxplot akses internet dan IPM
plot_boxplot <- ggplot(data_boxplot, aes(x = variabel, y = nilai, fill = variabel)) +
  geom_boxplot(alpha = 0.7) +
  labs(
    title = "Boxplot Akses Internet dan IPM",
    x = "Variabel",
    y = "Nilai"
  ) +
  theme_minimal() +
  theme(legend.position = "none")

# Menampilkan boxplot pada laporan
plot_boxplot

```



```

# Menyimpan boxplot ke dalam folder gambar
ggsave(
  filename = "../gambar/boxplot_akses_internet_ipm.png",
  plot = plot_boxplot,
  width = 8,
  height = 4,

```

```
    dpi = 300
  )
```

3.5 Uji Normalitas

Sebelum melakukan uji korelasi Pearson, perlu dipastikan bahwa data memenuhi asumsi normalitas. Oleh karena itu, dilakukan Uji Shapiro-Wilk pada variabel IPM.

```
shapiro_test <- shapiro.test(data$ipm)

cat("Hasil Uji Normalitas:\n")
```

Hasil Uji Normalitas:

```
print(shapiro_test)
```

Shapiro-Wilk normality test

```
data:  data$ipm
W = 0.96032, p-value < 2.2e-16
```

Pada pengujian ini digunakan hipotesis sebagai berikut:

- H_0 : Data berdistribusi normal.
- H_1 : Data tidak berdistribusi normal.

Berdasarkan hasil pengujian diperoleh nilai p-value < 0,05 sehingga H_0 ditolak. Dengan demikian, data IPM tidak berdistribusi normal.

Namun demikian, penelitian ini tetap menggunakan uji korelasi Pearson karena jumlah sampel yang digunakan sangat besar (sekitar 2.500 observasi). Pada ukuran sampel yang besar, penyimpangan kecil dari distribusi normal sering kali menyebabkan hasil uji Shapiro-Wilk menjadi signifikan. Oleh karena itu, uji Pearson masih digunakan untuk mengevaluasi kecenderungan hubungan linear antara kedua variabel.

3.6 Uji Korelasi Pearson

Tahap terakhir adalah menguji hubungan antara penetrasi akses internet dan IPM menggunakan Uji Korelasi Pearson. Pengujian ini dilakukan untuk mengetahui apakah terdapat hubungan yang signifikan antara kedua variabel serta mengukur kekuatan hubungan tersebut.

```
korelasi_test <- cor.test(  
  data$akses_internet,  
  data$ipm,  
  method = "pearson"  
)  
  
print(korelasi_test)
```

Pearson's product-moment correlation

```
data: data$akses_internet and data$ipm  
t = 0.10552, df = 2498, p-value = 0.916  
alternative hypothesis: true correlation is not equal to 0  
95 percent confidence interval:  
 -0.03709453  0.04131056  
sample estimates:  
      cor  
0.002111257
```

Hipotesis yang digunakan adalah:

- H_0 : Tidak terdapat hubungan yang signifikan antara akses internet dan IPM.
- H_1 : Terdapat hubungan yang signifikan antara akses internet dan IPM.

Berdasarkan hasil pengujian diperoleh nilai koefisien korelasi (r) sebesar 0,0021 dengan p-value sebesar 0,916.

Nilai koefisien korelasi yang sangat mendekati nol menunjukkan bahwa hubungan linear antara akses internet dan IPM hampir tidak ada. Selain itu, nilai p-value yang jauh lebih besar dari 0,05 menunjukkan bahwa hubungan tersebut tidak signifikan secara statistik.

Dengan demikian, H_0 tidak ditolak sehingga tidak terdapat bukti yang cukup untuk menyatakan adanya hubungan yang signifikan antara tingkat akses internet dan IPM pada dataset yang dianalisis.

Hasil ini menunjukkan bahwa akses internet tidak memiliki hubungan linear yang signifikan dengan IPM pada dataset yang dianalisis. Dengan demikian, variasi IPM tidak dapat dijelaskan hanya melalui variabel akses internet. Faktor lain seperti pendidikan, pendapatan, layanan kesehatan, atau indikator pembangunan lainnya dapat menjadi bahan pertimbangan untuk analisis lanjutan, tetapi tidak diuji secara langsung dalam penelitian ini.

3.7 Ringkasan Hasil Analisis

Berdasarkan seluruh tahapan analisis yang telah dilakukan, diperoleh beberapa temuan utama sebagai berikut:

1. Pemeriksaan awal menunjukkan adanya missing value pada beberapa variabel dalam dataset.
2. Karena fokus analisis adalah akses internet dan IPM, imputasi missing value dilakukan pada variabel akses_internet dan ipm menggunakan median.
3. Pemeriksaan outlier dilakukan melalui kolom catatan_data dan didukung dengan visualisasi boxplot.
4. Scatter plot menunjukkan bahwa hubungan antara akses internet dan IPM tidak membentuk pola linear yang kuat.
5. Histogram IPM menunjukkan bahwa distribusi data perlu diperiksa lebih lanjut melalui uji normalitas.
6. Hasil uji Shapiro-Wilk menunjukkan bahwa data IPM tidak berdistribusi normal.
7. Hasil uji korelasi Pearson menghasilkan koefisien korelasi sebesar 0,0021 dengan p-value sebesar 0,916, sehingga tidak ditemukan hubungan linear yang signifikan antara akses internet dan IPM.

Secara keseluruhan, hasil analisis menunjukkan bahwa tingkat akses internet tidak memiliki hubungan linear yang signifikan dengan IPM pada dataset yang digunakan. Oleh karena itu, variasi IPM kemungkinan tidak hanya dipengaruhi oleh akses internet, tetapi juga oleh faktor pembangunan lain yang lebih luas.