

**PENGARUH PENETRASI AKSES INTERNET TERHADAP
INDEKS PEMBANGUNAN MANUSIA (IPM):
PENDEKATAN PROBABILITAS DAN ANALISIS
KORELASI**



Mata Kuliah:
Probabilitas dan Statistika

Disusun oleh:

Alfitra Mumtaz Hanafi (J0403251058)
Ahmad Abian Hakim (J0403251069)
Rheika Muhammad Dzikrulhakim (J0403251068)
Zaky Alnadif (J0403251126)
Natasha Umaiza (J0403251046)
Hilannisa Nuraini Al'Basr (J0403251022)

**TEKNOLOGI REKAYASA PERANGKAT LUNAK
SEKOLAH VOKASI
IPB UNIVERSITY
BOGOR
2026**

Daftar Isi

BAB I: PENDAHULUAN	3
1.1 Latar Belakang	3
1.2 Rumusan Masalah	3
1.3 Tujuan Analisis	3
1.4 Manfaat Analisis	4
BAB II: METODOLOGI	4
2.1 Dataset	4
2.2 Tools yang Digunakan	7
2.3 Metode Analisis	7
BAB III. HASIL DAN PEMBAHASAN	8
3.1 Gambaran Umum Analisis	8
3.2 Pembersihan Data dan Penanganan Missing Value	8
3.2.1 Pemeriksaan Missing Value	9
3.2.2 Pemeriksaan Outlier	10
3.3 Analisis Deskriptif	11
3.4 Visualisasi Data	12
3.4.1 Grafik Missing Value pada Setiap Variabel	12
3.4.2 Grafik Jumlah Data Berdasarkan Catatan Data	13
3.4.3 Scatter Plot Hubungan Akses Internet dan IPM	15
3.4.4 Histogram Distribusi IPM	16
3.4.5 Boxplot Akses Internet dan IPM	18
3.5 Uji Normalitas	19
3.6 Uji Korelasi Pearson	20
BAB IV: KESIMPULAN	21
4.1 Kesimpulan Utama	21
4.2 Insight	22
4.3 Saran	22
DAFTAR PUSTAKA	22
LAMPIRAN	23

BAB I: PENDAHULUAN

1.1 Latar Belakang

Dalam era modern, definisi infrastruktur pembangunan tidak lagi terbatas pada pembangunan fisik, melainkan telah berekspansi ke infrastruktur digital. Akses internet kini menjadi salah satu fasilitas penting yang berperan dalam mendukung akses informasi, pendidikan, layanan publik, dan aktivitas ekonomi masyarakat. Kesenjangan digital (*digital divide*) sering kali menjadi salah satu faktor yang berkaitan dengan ketimpangan pembangunan antarwilayah (Ndubuisi et al., 2021).

Indeks Pembangunan Manusia (IPM) digunakan untuk melihat capaian pembangunan manusia dari aspek kesehatan, pendidikan, dan standar hidup layak. Konsep ini menunjukkan bahwa pembangunan tidak hanya diukur dari pertumbuhan ekonomi, tetapi juga dari kualitas hidup masyarakat secara lebih luas (UNDP, 2022). Oleh karena itu, analisis ini dilakukan untuk melihat apakah tingkat akses internet memiliki hubungan linear yang signifikan dengan IPM pada dataset pembangunan wilayah yang digunakan.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam analisis ini adalah:

1. Bagaimana kondisi missing value dan outlier pada dataset pembangunan wilayah?
2. Bagaimana gambaran statistik deskriptif variabel akses internet dan IPM?
3. Bagaimana pola visual hubungan antara akses internet dan IPM?
4. Apakah data IPM berdistribusi normal?
5. Apakah terdapat hubungan linear yang signifikan antara akses internet dan IPM?

1.3 Tujuan Analisis

Analisis ini memiliki tujuan antara lain:

1. Mengidentifikasi dan menangani *missing value* serta *outlier* pada dataset pembangunan wilayah, khususnya pada variabel akses internet dan IPM.
2. Melakukan statistika deskriptif untuk memetakan persebaran data digitalisasi dan kesejahteraan penduduk.
3. Membangun visualisasi data yang informatif untuk melihat tren sebaran antarvariabel secara grafis.
4. Menguji distribusi probabilitas atau normalitas pada data IPM wilayah.
5. Membuktikan secara statistik hipotesis korelasi antara penetrasi akses internet dengan skor IPM.

1.4 Manfaat Analisis

Analisis ini diharapkan dapat memberikan gambaran mengenai proses pengolahan dataset pembangunan wilayah menggunakan R, mulai dari pemeriksaan kualitas data, statistika deskriptif, visualisasi, pengujian distribusi, hingga analisis korelasi. Selain itu, hasil analisis ini dapat menjadi bahan awal untuk memahami apakah akses internet memiliki hubungan linear dengan IPM pada dataset yang digunakan.

BAB II: METODOLOGI

2.1 Dataset

Penelitian ini menggunakan dataset `pembangunan_wilayah_missing_outlier.csv` yang merepresentasikan kondisi indikator pembangunan makro di berbagai wilayah kabupaten/kota di Indonesia. Dataset ini mencakup dimensi ekonomi, sosial, dan infrastruktur wilayah.

Fokus pengujian utama dibatasi pada dua variabel, yaitu `akses_internet` sebagai variabel independen dan `ipm` sebagai variabel dependen. Variabel `akses_internet` menunjukkan persentase ketersediaan akses internet, sedangkan `ipm` menunjukkan nilai Indeks Pembangunan Manusia. Dataset ini juga sengaja dibuat memiliki *missing value* dan *outlier* agar proses pembersihan data dapat dilakukan sebelum analisis statistik.

Untuk memahami struktur dataset, dilakukan pengecekan menggunakan beberapa fungsi dasar R sebagai berikut.

```
# Mengatur lebar output agar tidak melebar di PDF
options(width = 65)

# Membaca dataset
data <- read.csv("../dataset/pembangunan_wilayah_missing_outlier.csv")

# Menampilkan jumlah baris dan kolom dataset
cat("Jumlah baris dan kolom dataset:\n")
```

Jumlah baris dan kolom dataset:

```
print(dim(data))
```

```
[1] 2500  13
```

```
# Menampilkan nama variabel dalam dataset
cat("\nNama variabel dalam dataset:\n")
```

Nama variabel dalam dataset:

```
print(names(data))
```

```
[1] "wilayah"      "provinsi"      "tahun"
[4] "pdrb_perkapita" "kemiskinan"    "pengangguran"
[7] "ipm"          "harapan_hidup" "rata_lama_sekolah"
[10] "akses_internet" "jalan_baik"    "air_bersih"
[13] "catatan_data"
```

```
# Melihat struktur dan tipe data setiap variabel
cat("\nStruktur dataset:\n")
```

Struktur dataset:

```
str(data, vec.len = 1, give.attr = FALSE)
```

```
'data.frame':  2500 obs. of  13 variables:
 $ wilayah      : chr  "Kabupaten/Kota_1" ...
 $ provinsi     : chr  "Jawa Barat" ...
 $ tahun        : int   2022 2022 ...
 $ pdrb_perkapita : num   38403994 ...
 $ kemiskinan   : num    19.7 ...
 $ pengangguran : num    4.73 4.43 ...
 $ ipm          : num    80.2 ...
 $ harapan_hidup : num    75.8 ...
 $ rata_lama_sekolah: num    8.41 5.79 ...
 $ akses_internet : num    63.9 ...
 $ jalan_baik    : num    53.9 ...
 $ air_bersih    : num    43.1 ...
 $ catatan_data  : chr  "Normal" ...
```

```
# Menampilkan beberapa data awal pada variabel utama
cat("\nContoh data awal pada variabel utama:\n")
```

Contoh data awal pada variabel utama:

```
head(data[, c("wilayah", "provinsi", "tahun", "akses_internet", "ipm", "catatan_data")])
```

```
      wilayah      provinsi tahun akses_internet  ipm
1 Kabupaten/Kota_1 Jawa Barat  2022      63.86 80.16
2 Kabupaten/Kota_2 Jawa Timur  2022      66.61 55.05
3 Kabupaten/Kota_3 Kalimantan Timur  2020      64.73 78.70
4 Kabupaten/Kota_4 DKI Jakarta  2022      44.59 73.27
5 Kabupaten/Kota_5 Sulawesi Selatan  2023      52.72 72.90
6 Kabupaten/Kota_6 Jawa Timur  2020      55.63 65.11
catatan_data
1      Normal
2      Normal
3      Normal
4      Normal
5      Normal
6      Normal
```

Berdasarkan hasil pengecekan, dataset terdiri dari 2.500 observasi dan 13 variabel. Variabel dalam dataset terdiri atas variabel kategorik seperti `wilayah`, `provinsi`, dan `catatan_data`, serta variabel numerik seperti `tahun`, `pdrb_perkapita`, `kemiskinan`, `pengangguran`, `ipm`, `harapan_hidup`, `rata_lama_sekolah`, `akses_internet`, `jalan_baik`, dan `air_bersih`.

Berikut adalah ringkasan arti setiap variabel dalam dataset:

Variabel	Tipe Data	Keterangan
<code>wilayah</code>	Kategorik	Identitas nama kabupaten atau kota
<code>provinsi</code>	Kategorik	Provinsi tempat wilayah administratif berada
<code>tahun</code>	Numerik	Tahun pengamatan data
<code>pdrb_perkapita</code>	Numerik	Produk Domestik Regional Bruto per kapita
<code>kemiskinan</code>	Numerik	Persentase penduduk miskin

Variabel	Tipe Data	Keterangan
pengangguran	Numerik	Tingkat pengangguran terbuka
ipm	Numerik	Indeks Pembangunan Manusia
harapan_hidup	Numerik	Angka harapan hidup penduduk
rata_lama_sekolah	Numerik	Rata-rata lama sekolah penduduk
akses_internet	Numerik	Persentase akses internet
jalan_baik	Numerik	Persentase jalan dalam kondisi baik
air_bersih	Numerik	Persentase akses air bersih
catatan_data	Kategorik	Penanda kualitas data seperti Normal, Missing Value, dan Outlier

2.2 Tools yang Digunakan

Seluruh tahapan pembersihan dan pengujian data dieksekusi menggunakan bahasa pemrograman **R**. R digunakan karena mendukung proses komputasi statistik, eksplorasi data, dan visualisasi secara sistematis (Field et al., 2012). Dokumen ini disusun menggunakan **Quarto**, yaitu sistem penulisan yang memungkinkan integrasi narasi, kode, dan output analisis dalam satu laporan yang dapat direproduksi. Pustaka tambahan seperti **ggplot2** digunakan untuk membangun visualisasi grafis yang lebih informatif.

2.3 Metode Analisis

Pendekatan statistik yang diterapkan meliputi:

- **Penanganan Data:** Imputasi data kosong diselesaikan menggunakan Median Imputation. Metode ini dipilih karena median lebih tahan terhadap pengaruh nilai ekstrem atau outlier dibandingkan rata-rata, sehingga lebih sesuai digunakan ketika dataset memiliki potensi nilai ekstrem (Little & Rubin, 2019). Karena fokus penelitian adalah menguji hubungan antara **akses internet dan IPM**, analisis selanjutnya dilakukan menggunakan data hasil imputasi pada variabel utama tanpa menghapus observasi yang terindikasi sebagai nilai ekstrem.
- **Statistika Deskriptif:** Analisis deskriptif digunakan untuk melihat karakteristik awal variabel akses internet dan IPM, seperti nilai minimum, maksimum, median, rata-rata, dan kuartil.

- **Visualisasi Data:** Visualisasi digunakan untuk membantu membaca kondisi missing value, catatan kualitas data, pola hubungan, distribusi IPM, serta kemungkinan adanya nilai ekstrem.
- **Uji Normalitas:** Uji Shapiro-Wilk digunakan untuk melihat apakah data IPM mendekati distribusi normal.
- **Uji Korelasi:** Uji korelasi Pearson digunakan untuk melihat kekuatan dan arah hubungan linear antara akses internet dan IPM.

BAB III. HASIL DAN PEMBAHASAN

3.1 Gambaran Umum Analisis

Penelitian ini difokuskan untuk menguji apakah terdapat hubungan antara penetrasi akses internet dengan Indeks Pembangunan Manusia (IPM).

Secara sistematis, prosedur analisis dilakukan dalam beberapa tahapan krusial, dimulai dari persiapan data, eksplorasi deskriptif, visualisasi pola hubungan antarvariabel, pengujian asumsi normalitas, hingga diakhiri dengan uji korelasi. Mengingat dataset yang digunakan mengandung missing value, langkah awal yang dilakukan adalah pembersihan data untuk menjamin validitas hasil statistik. Setelah data dipastikan lengkap, dilakukan eksplorasi untuk memetakan karakteristik variabel, yang kemudian dilanjutkan dengan pengujian statistik untuk menjawab hipotesis mengenai signifikansi hubungan antara akses internet dan IPM.

3.2 Pembersihan Data dan Penanganan Missing Value

Tahap awal dalam alur kerja analisis ini adalah memastikan integritas data melalui pemeriksaan kualitas variabel. Keberadaan missing value pada dataset berisiko menimbulkan bias dalam perhitungan statistik sehingga diperlukan tindakan perbaikan sebelum analisis dilakukan. Untuk menangani hal tersebut, metode Median Imputation diterapkan, yakni mengganti nilai yang hilang dengan nilai median dari variabel terkait. Pemilihan metode ini didasarkan pada karakteristik median yang lebih resisten (*robust*) terhadap pengaruh nilai ekstrem (*pencilan*) dibandingkan dengan metode rata-rata (*mean*).

Berdasarkan pemeriksaan awal, ditemukan adanya missing value pada variabel akses internet dan IPM. Setelah proses imputasi dilakukan, data kini telah lengkap dan memenuhi syarat untuk diproses ke tahap analisis selanjutnya.

3.2.1 Pemeriksaan Missing Value

```
# Membuat folder gambar jika folder tersebut belum tersedia
if (!dir.exists("../gambar")) {
  dir.create("../gambar")
}

# Membaca dataset
data <- read.csv("../dataset/pembangunan_wilayah_missing_outlier.csv")

# Mengecek jumlah missing value pada seluruh variabel
missing_semua_variabel <- colSums(is.na(data))

cat("Jumlah missing value pada seluruh variabel:\n")
```

Jumlah missing value pada seluruh variabel:

```
print(missing_semua_variabel)
```

wilayah	provinsi	tahun
0	0	0
pdrb_perkapita	kemiskinan	pengangguran
25	24	25
ipm	harapan_hidup	rata_lama_sekolah
25	0	0
akses_internet	jalan_baik	air_bersih
25	25	0
catatan_data		
0		

```
# Mengecek jumlah missing value pada variabel utama
na_internet_awal <- sum(is.na(data$akses_internet))
na_ipm_awal <- sum(is.na(data$ipm))

cat("\nJumlah NA Akses Internet sebelum diolah:", na_internet_awal, "\n")
```

Jumlah NA Akses Internet sebelum diolah: 25

```
cat("Jumlah NA IPM sebelum diolah:", na_ipm_awal, "\n")
```

Jumlah NA IPM sebelum diolah: 25

```
# Mengisi missing value pada variabel utama dengan median
data$akses_internet[is.na(data$akses_internet)] <- median(data$akses_internet, na.rm = TRUE)
data$ipm[is.na(data$ipm)] <- median(data$ipm, na.rm = TRUE)

# Mengecek ulang missing value pada variabel utama setelah imputasi
cat("\nJumlah NA Akses Internet setelah diolah:", sum(is.na(data$akses_internet)), "\n")
```

Jumlah NA Akses Internet setelah diolah: 0

```
cat("Jumlah NA IPM setelah diolah:", sum(is.na(data$ipm)), "\n")
```

Jumlah NA IPM setelah diolah: 0

Berdasarkan hasil pemeriksaan, missing value ditemukan pada beberapa variabel dalam dataset. Namun, karena analisis ini berfokus pada hubungan antara `akses_internet` dan `ipm`, proses imputasi hanya dilakukan pada kedua variabel tersebut. Nilai yang hilang pada variabel `akses_internet` dan `ipm` digantikan menggunakan median masing-masing variabel sehingga data utama yang digunakan dalam analisis menjadi lengkap.

3.2.2 Pemeriksaan Outlier

```
# Mengecek jumlah data berdasarkan catatan data
cat("Jumlah data berdasarkan catatan_data:\n")
```

Jumlah data berdasarkan catatan_data:

```
table(data$catatan_data)
```

Missing Value	Normal	Outlier
143	2337	20

Kolom `catatan_data` menunjukkan bahwa sebagian observasi dalam dataset teridentifikasi sebagai outlier, yakni nilai-nilai yang menyimpang secara signifikan dari pola mayoritas data. Mengingat fokus penelitian adalah menguji hubungan antara akses internet dan IPM, observasi tersebut tetap dipertahankan dalam analisis. Penghapusan outlier justru berisiko mempersempit variasi data dan mengurangi representativitas hasil, sehingga pendekatan yang dipilih adalah membiarkan data apa adanya setelah imputasi pada variabel utama diselesaikan.

3.3 Analisis Deskriptif

Setelah proses pembersihan data selesai, dilakukan analisis deskriptif untuk memperoleh gambaran umum mengenai karakteristik data. Analisis ini bertujuan mengetahui ukuran pemusatan dan penyebaran data seperti nilai minimum, maksimum, median, rata-rata, dan kuartil.

```
cat("Ringkasan Statistik Akses Internet:\n")
```

Ringkasan Statistik Akses Internet:

```
summary(data$akses_internet)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.01	39.09	58.09	58.78	78.58	97.99

```
cat("\nRingkasan Statistik IPM:\n")
```

Ringkasan Statistik IPM:

```
summary(data$ipm)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
55.01	62.60	69.89	69.90	77.09	84.99

Ringkasan statistik menggambarkan karakteristik sebaran nilai akses internet dan IPM di seluruh wilayah yang tercakup dalam dataset. Dari output yang dihasilkan, terlihat adanya variasi yang cukup lebar antarwilayah, baik pada tingkat penetrasi internet maupun skor IPM-nya. Kondisi ini mengindikasikan bahwa ketimpangan antardaerah masih cukup nyata, dengan sejumlah wilayah yang sudah berada jauh di atas rata-rata sementara sebagian lainnya masih tertinggal. Gambaran awal ini menjadi pijakan penting sebelum melangkah ke analisis hubungan antarvariabel pada tahap berikutnya.

3.4 Visualisasi Data

Visualisasi data digunakan untuk membantu melihat kondisi missing value, catatan kualitas data, pola hubungan antarvariabel, bentuk distribusi, serta kemungkinan adanya nilai ekstrem pada variabel yang dianalisis. Pada bagian ini digunakan lima visualisasi, yaitu grafik missing value, grafik catatan data, scatter plot, histogram, dan boxplot.

3.4.1 Grafik Missing Value pada Setiap Variabel


Grafik missing value digunakan untuk melihat jumlah nilai kosong pada setiap variabel dalam dataset. Visualisasi ini membantu menunjukkan variabel mana saja yang memiliki data tidak lengkap sebelum proses analisis dilakukan.

```
# Memanggil package ggplot2 untuk membuat visualisasi data
library(ggplot2)

# Membuat data jumlah missing value tiap variabel
missing_df <- data.frame(
  variabel = names(missing_semua_variabel),
  jumlah = as.numeric(missing_semua_variabel)
)

# Membuat grafik missing value
plot_missing <- ggplot(missing_df, aes(x = reorder(variabel, jumlah), y = jumlah)) +
  geom_col(fill = "#3498db") +
  coord_flip() +
  labs(
    title = "Jumlah Missing Value pada Setiap Variabel",
    x = "Variabel",
    y = "Jumlah Missing Value"
  ) +
  theme_minimal()

# Menampilkan grafik pada laporan
plot_missing
```



```
# Menyimpan grafik ke dalam folder gambar
ggsave(
  filename = "../gambar/gambar_1_missing_value_variabel.png",
  plot = plot_missing,
  width = 8,
  height = 4,
  dpi = 300
)
```

Berdasarkan Gambar 1, terlihat bahwa missing value tidak hanya terdapat pada variabel utama, tetapi juga muncul pada beberapa variabel lain dalam dataset. Grafik ini digunakan untuk melihat kondisi kelengkapan data secara umum. Namun, karena analisis difokuskan pada hubungan antara akses internet dan IPM, proses imputasi hanya dilakukan pada variabel `akses_internet` dan `ipm`.


3.4.2 Grafik Jumlah Data Berdasarkan Catatan Data

Grafik catatan data digunakan untuk melihat jumlah data berdasarkan kategori yang tersedia pada kolom `catatan_data`. Visualisasi ini membantu mengetahui berapa banyak data yang termasuk normal, missing value, maupun outlier.

```
# Membuat data jumlah berdasarkan catatan_data
catatan_df <- as.data.frame(table(data$catatan_data))
colnames(catatan_df) <- c("catatan_data", "jumlah")
```

```
# Membuat grafik catatan data
plot_catatan <- ggplot(catatan_df, aes(x = catatan_data, y = jumlah)) +
  geom_col(fill = "#e67e22") +
  labs(
    title = "Jumlah Data Berdasarkan Catatan Data",
    x = "Catatan Data",
    y = "Jumlah Data"
  ) +
  theme_minimal()

# Menampilkan grafik pada laporan
plot_catatan
```



```
# Menyimpan grafik ke dalam folder gambar
ggsave(
  filename = "../gambar/gambar_2_catatan_data.png",
  plot = plot_catatan,
  width = 8,
  height = 4,
  dpi = 300
)
```

Berdasarkan Gambar 2, sebagian besar data berada pada kategori normal, sedangkan sebagian kecil data memiliki catatan missing value dan outlier. Grafik ini menunjukkan bahwa dataset

memang memiliki beberapa catatan kualitas data yang perlu diperhatikan. Pada penelitian ini, outlier tetap dipertahankan karena analisis difokuskan untuk melihat hubungan umum antara akses internet dan IPM.


3.4.3 Scatter Plot Hubungan Akses Internet dan IPM

Scatter plot digunakan untuk melihat pola hubungan antara tingkat akses internet dan IPM. Visualisasi ini membantu menunjukkan apakah kenaikan akses internet cenderung diikuti oleh kenaikan IPM atau tidak.

```
# Membuat scatter plot hubungan akses internet dan IPM
plot_scatter <- ggplot(data, aes(x = akses_internet, y = ipm)) +
  geom_point(color = "#2980b9", alpha = 0.5) +
  geom_smooth(method = "lm", color = "#e74c3c", se = TRUE) +
  labs(
    title = "Hubungan Akses Internet dan IPM",
    x = "Akses Internet (%)",
    y = "IPM"
  ) +
  theme_minimal()

# Menampilkan plot pada laporan
plot_scatter
```

```
`geom_smooth()` using formula = 'y ~ x'
```



```
# Menyimpan plot ke dalam folder gambar
ggsave(
  filename = "../gambar/gambar_3_scatter_akses_internet_ipm.png",
  plot = plot_scatter,
  width = 8,
  height = 4,
  dpi = 300
)
```

```
`geom_smooth()` using formula = 'y ~ x'
```

Berdasarkan Gambar 3, titik-titik data terlihat menyebar secara acak dan tidak membentuk pola naik atau turun yang jelas. Garis regresi pada grafik juga hampir datar, sehingga hubungan linear antara akses internet dan IPM belum terlihat kuat secara visual.


Dari visualisasi ini, dapat dikatakan bahwa wilayah dengan akses internet yang lebih tinggi tidak selalu memiliki IPM yang lebih tinggi dalam dataset ini. Oleh karena itu, hasil scatter plot perlu diperkuat dengan uji korelasi Pearson untuk mengetahui apakah hubungan kedua variabel signifikan secara statistik.

3.4.4 Histogram Distribusi IPM

Histogram digunakan untuk melihat bentuk distribusi nilai IPM pada dataset. Visualisasi ini membantu memberikan gambaran awal mengenai apakah data IPM cenderung menyebar secara normal atau tidak sebelum dilakukan uji normalitas.


```
# Membuat histogram untuk melihat distribusi nilai IPM
plot_histogram_ipm <- ggplot(data, aes(x = ipm)) +
  geom_histogram(bins = 30, fill = "#3498db", color = "white") +
  labs(
    title = "Distribusi Nilai IPM",
    x = "IPM",
    y = "Frekuensi"
  ) +
  theme_minimal()

# Menampilkan histogram IPM pada laporan
plot_histogram_ipm
```



```
# Menyimpan histogram IPM ke dalam folder gambar
ggsave(
  filename = "../gambar/gambar_4_histogram_ipm.png",
  plot = plot_histogram_ipm,
  width = 8,
  height = 4,
  dpi = 300
)
```

Berdasarkan Gambar 4, nilai IPM tersebar pada beberapa rentang nilai dan tidak sepenuhnya membentuk pola lonceng yang simetris. Hal ini menunjukkan bahwa distribusi IPM perlu diperiksa lebih lanjut sebelum digunakan dalam pengujian statistik.

Histogram ini hanya digunakan sebagai gambaran awal untuk melihat bentuk sebaran data. Keputusan mengenai normal atau tidaknya distribusi IPM tetap didasarkan pada hasil uji Shapiro-Wilk pada bagian berikutnya.


3.4.5 Boxplot Akses Internet dan IPM

Boxplot digunakan untuk melihat sebaran data, nilai tengah, rentang data, serta kemungkinan adanya nilai ekstrem pada variabel akses internet dan IPM.

```
# Mengubah data akses internet dan IPM ke format panjang
data_boxplot <- data.frame(
  variabel = rep(c("Akses Internet", "IPM"), each = nrow(data)),
  nilai = c(data$akses_internet, data$ipm)
)

# Membuat boxplot akses internet dan IPM
plot_boxplot <- ggplot(data_boxplot, aes(x = variabel, y = nilai, fill = variabel)) +
  geom_boxplot(alpha = 0.7) +
  labs(
    title = "Boxplot Akses Internet dan IPM",
    x = "Variabel",
    y = "Nilai"
  ) +
  theme_minimal() +
  theme(legend.position = "none")

# Menampilkan boxplot pada laporan
plot_boxplot
```



```
# Menyimpan boxplot ke dalam folder gambar
ggsave(
  filename = "../gambar/gambar_5_boxplot_akses_internet_ipm.png",
  plot = plot_boxplot,
  width = 8,
  height = 4,
  dpi = 300
)
```

Berdasarkan Gambar 5, boxplot menunjukkan sebaran nilai pada variabel akses internet dan IPM. Visualisasi ini membantu melihat nilai tengah, rentang data, serta kemungkinan adanya nilai ekstrem. Jika terdapat titik yang berada jauh dari kotak utama, maka titik tersebut dapat menjadi indikasi outlier. Namun, outlier tetap dipertahankan karena analisis ini berfokus pada hubungan umum antarvariabel, bukan pada penghapusan data ekstrem.

3.5 Uji Normalitas

Sebelum melakukan uji korelasi Pearson, perlu dipastikan bahwa data memenuhi asumsi normalitas. Oleh karena itu, dilakukan Uji Shapiro-Wilk pada variabel IPM.

```
shapiro_test <- shapiro.test(data$ipm)

cat("Hasil Uji Normalitas:\n")
```

Hasil Uji Normalitas:

```
print(shapiro_test)
```

Shapiro-Wilk normality test

data: data\$ipm

W = 0.96032, p-value < 2.2e-16

Pada pengujian ini digunakan hipotesis sebagai berikut:

- H0 : Data berdistribusi normal.
- H1 : Data tidak berdistribusi normal.

Berdasarkan hasil pengujian diperoleh nilai p-value < 0,05 sehingga H0 ditolak. Dengan demikian, data IPM tidak berdistribusi normal.

Namun demikian, jumlah sampel yang digunakan cukup besar, yaitu sekitar 2.500 observasi. Pada ukuran sampel yang besar, penyimpangan kecil dari distribusi normal sering kali membuat hasil uji normalitas menjadi signifikan secara statistik (Ghasemi & Zahediasl, 2012). Oleh karena itu, uji korelasi Pearson tetap digunakan untuk melihat kecenderungan hubungan linear antara akses internet dan IPM.

3.6 Uji Korelasi Pearson

Tahap terakhir adalah menguji hubungan antara penetrasi akses internet dan IPM menggunakan Uji Korelasi Pearson. Pengujian ini dilakukan untuk mengetahui apakah terdapat hubungan yang signifikan antara kedua variabel serta mengukur kekuatan hubungan tersebut.

```
korelasi_test <- cor.test(  
  data$akses_internet,  
  data$ipm,  
  method = "pearson"  
)  
  
print(korelasi_test)
```

Pearson's product-moment correlation

```
data: data$akses_internet and data$ipm
t = 0.10552, df = 2498, p-value = 0.916
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.03709453  0.04131056
sample estimates:
      cor
0.002111257
```

Hipotesis yang digunakan adalah:

- H0 : Tidak terdapat hubungan yang signifikan antara akses internet dan IPM.
- H1 : Terdapat hubungan yang signifikan antara akses internet dan IPM.

Berdasarkan hasil pengujian diperoleh nilai koefisien korelasi (r) sebesar 0,0021 dengan p-value sebesar 0,916.

Nilai koefisien korelasi yang sangat mendekati nol menunjukkan bahwa hubungan linear antara akses internet dan IPM hampir tidak ada. Selain itu, nilai p-value yang jauh lebih besar dari 0,05 menunjukkan bahwa hubungan tersebut tidak signifikan secara statistik.

Dengan demikian, H0 tidak ditolak sehingga tidak terdapat bukti yang cukup untuk menyatakan adanya hubungan yang signifikan antara tingkat akses internet dan IPM pada dataset yang dianalisis.

Hasil ini menunjukkan bahwa akses internet tidak memiliki hubungan linear yang signifikan dengan IPM pada dataset yang dianalisis. Dengan demikian, variasi IPM tidak dapat dijelaskan hanya melalui variabel akses internet. Faktor lain seperti pendidikan, pendapatan, layanan kesehatan, atau indikator pembangunan lainnya dapat menjadi bahan pertimbangan untuk analisis lanjutan, tetapi tidak diuji secara langsung dalam penelitian ini.

BAB IV: KESIMPULAN

4.1 Kesimpulan Utama

Berdasarkan hasil analisis, missing value pada variabel `akses_internet` dan `ipm` berhasil ditangani menggunakan Median Imputation. Analisis deskriptif menunjukkan bahwa nilai akses internet dan IPM memiliki variasi antarwilayah. Lima visualisasi yang dibuat juga membantu memperlihatkan kondisi missing value, catatan data, pola hubungan, distribusi IPM, serta kemungkinan nilai ekstrem.

Hasil scatter plot menunjukkan bahwa hubungan antara akses internet dan IPM tidak membentuk pola linear yang kuat. Selain itu, uji Shapiro-Wilk menunjukkan bahwa data IPM tidak berdistribusi normal karena p-value kurang dari 0,05.

Pada uji korelasi Pearson, diperoleh koefisien korelasi sebesar 0,0021 dengan p-value sebesar 0,916. Nilai tersebut menunjukkan bahwa hubungan linear antara akses internet dan IPM sangat lemah dan tidak signifikan secara statistik.

Secara keseluruhan, tingkat akses internet tidak memiliki hubungan linear yang signifikan dengan IPM pada dataset yang digunakan dalam penelitian ini.

4.2 Insight

Hasil analisis menunjukkan bahwa akses internet belum cukup kuat untuk menjelaskan variasi IPM secara linear pada dataset ini. Artinya, wilayah dengan akses internet yang lebih tinggi tidak selalu memiliki nilai IPM yang lebih tinggi. Temuan ini menunjukkan bahwa pembangunan manusia tidak dapat dilihat hanya dari satu indikator digital, tetapi perlu mempertimbangkan indikator lain seperti pendidikan, kesehatan, ekonomi, dan infrastruktur.

4.3 Saran

Untuk analisis lanjutan, disarankan menggunakan lebih banyak variabel pembangunan seperti tingkat kemiskinan, pengangguran, PDRB per kapita, rata-rata lama sekolah, harapan hidup, akses air bersih, dan kondisi jalan baik. Analisis lanjutan juga dapat menggunakan korelasi antar banyak variabel atau model regresi agar faktor-faktor yang berhubungan dengan IPM dapat dipahami secara lebih luas.

DAFTAR PUSTAKA

- Badan Pusat Statistik. (2023). *Indeks Pembangunan Manusia 2023*. Badan Pusat Statistik Republik Indonesia.
- Field, A., Miles, J., & Field, Z. (2012). *Discovering Statistics Using R*. SAGE Publications.
- Ghasemi, A., & Zahediasl, S. (2012). Normality tests for statistical analysis: A guide for non-statisticians. *International Journal of Endocrinology and Metabolism*, 10(2), 486–489.
- Little, R. J. A., & Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3rd ed.). John Wiley & Sons.
- Ndubuisi, G., Otioma, C., & Tetteh, G. K. (2021). Digital infrastructure and human development. *Telecommunications Policy*, 45(8), 102154.

United Nations Development Programme. (2022). *Human Development Report 2021/2022: Uncertain Times, Unsettled Lives*. United Nations Development Programme.

LAMPIRAN

Lampiran berisi file pendukung yang digunakan dalam penyusunan laporan proyek akhir ini.

1. Script R disimpan pada folder **script**.
2. Dataset disimpan pada folder **dataset**.
3. Hasil visualisasi disimpan pada folder **gambar**.
4. Laporan akhir dalam format **.qmd** dan **.pdf** disimpan pada folder **dokumen**.

Adapun hasil visualisasi yang disimpan pada folder **gambar** adalah:

1. `gambar_1_missing_value_variabel.png`
2. `gambar_2_catatan_data.png`
3. `gambar_3_scatter_akses_internet_ipm.png`
4. `gambar_4_histogram_ipm.png`
5. `gambar_5_boxplot_akses_internet_ipm.png`